Сегодня я помержил в ClickHouse 30 пул-реквестов, а он всё ещё не тормозит: автотесты производительности

Александр Кузьменков Яндекс





Что за ClickHouse?



- Колоночная СУБД для аналитики
- SQL
- Отчёты по сырым большим данным в реальном времени^2
- Базовая технология Яндекс.
 Метрики
- Не тормозит

Скачайте слайды





Почему не тормозит?

- Эффективное хранение данных
 - Колонки
 - Сжатие
- Эффективная обработка
 - Многопоточная, распределённая, специализированные векторные алгоритмы
- Много бенчмарков



Бенчмарки

- Микробенчмарки для конкретного алгоритма
 - Оптимизация агрегатной функции в ClickHouse
- end-to-end
 - На синтетических данных
 - На реальных данных
- Бенчмарки оборудования
 - На моём телефоне



Непрерывное автоматическое тестирование

- Для каждого PR
- Для каждого коммита в мастер/релизную ветку
- Изменения за апрель (<u>интерактив здесь</u>):

```
__authors___prs__
| 44 | 401 |
______
___
___tests___queries__
| 215 | 2640 |
```





Performance — 3 faster, 72 unstable

Details


18 SELECT count() FROM test logical functions. 4 1 Nullable UInt8 WHERE NOT ignore(xor(x1,x2,x3,x4))

9 SELECT count() FROM (SELECT toNullable(materialize(1)) AS x1, toNullable(materialize(1)) AS x2 FROM

19 SELECT count() FROM test logical functions. 4 1 Nullable Mixed WHERE NOT ignore(xor(x1,x2,x3,x4))

ClickHouse performance comparison

Tested Commits?



Merge 7467c5e3cf8ee702e75e80942ac9eba4402df69a into dd31634ba44168104d9e23b218148a2dad01b41e Changes in Performance? Old, s New, s Ratio of Relative p < 0.01 Test # Query

speedup (-) difference threshold

0.075

0.193

0.163

0.262

or (new - old) slowdown (+) / old

-2.166x

-1.359x

- 0.317 0.140 -2.264x

- - - -0.559
 - -0.539

-0.265

- 0.538 logical functions small

- 0.558 logical functions medium

0.264 logical functions medium

Что мерить

- Время выполнения запроса
- Несколько раз
- Среднее не видит странностей
- min/max неустойчивы к выбросам
- Мерим медиану




С чем сравнивать

- Модельное распределение
- Исторические данные
 - Разное железо
 - Разное окружение
- Предыдущая версия сервера, запущенная на том же сервере



Как сравнивать

Box, Hunter, Hunter, "Statistics for experimenters", p. 78: "A Randomized Design Used in the Comparison of Standard and Modified Fertilizer Mixtures for Tomato Plants."





Randomization distribution

- Что даёт?
 - Разницу, которую можно увидеть, даже сравнивая сервер сам с собой ("S").
 - o p < 0.01 <==> 99 перцентиль.
 - 2000 * 1% = 20 false positive на прогон.
 - Для любой метрики (напр., потребление памяти)
- Как интерпретировать
 - D < 5% неинтересно
 - D < S статистически незначимо
 - D > S производительность изменилась
 - S > 5% плохой запрос (низкая точность)



Изменения производительности

- Поменяли код в этом месте
- Статистический ложноположительный результат
- Поменялась сборка
 - граничные эффекты в компиляторе
 - о разное расположение функций в бинарнике
 - BOLT, Propeller



Встроенный профайлер

```
set query profiler real time period ns = 10000000;
clickhouse-client -q "SELECT
   arrayStringConcat(
      arrayMap(
          x -> concat(splitByChar('/', addressToLine(x))[-1],
              '#', demangle(addressToSymbol(x))),
          trace),
      ';') AS stack,
   count(*) AS samples
FROM system.trace log
WHERE trace type = 'Real'
   AND query id = '4aac5305-b27f-4a5a-91c3-61c0cf52ec2a'
GROUP BY trace" \
   | flamegraph.pl
```




Встроенный профайлер (2)

```
Flame Graph
Reset Zoom
       c.. clickhouse#DB::(anonymous namespace)::convertAnyColumnToBool(DB::IColumn const*, DB::PODArray<char8 t, 4096ul, Allocator<false, false>, 15ul,... click...
        clickhouse#DB::FunctionsLogicalDetail::FunctionAnyArityLogical<br/>
Colu... 1::vector<DB::Colu... 1::vector<br/>
Colu... 2::vector<br/>
C
                                                                                                                                                                                                                                                                                                                                                                                                                                                               cl..
        clickhouse#DB::DefaultExecutable::execute(std:: 1::vector<DB::ColumnWithTypeAndName, std:: 1::allocator<DB::ColumnWithTypeAndName> > const&, std:..
                                                                                                                                                                                                                                                                                                                                                                                                                                                             cli..
        clickhouse#DB::ExecutableFunctionAdaptor::executeWithoutLowCardinalityColumns(std::__1::vector<DB::ColumnWithTypeAndName, std::__1::allocator<DB::Co..
       clickhouse#DB::ExecutableFunctionAdaptor::defaultImplementationForNulls(std:: 1::vector<DB::ColumnWithTypeAndName, std:: 1::allocator<DB::ColumnWithTypeAndName>>..
       clickhouse#DB::ExecutableFunctionAdaptor::executeWithoutLowCardinalityColumns(std::__1::vector<DB::ColumnWithTypeAndName, std::__1::allocator<DB::ColumnWithTypeAnd...
       clickhouse#DB::ExecutableFunctionAdaptor::execute(std::__1::vector<DB::ColumnWithTypeAndName, std::__1::allocator<DB::ColumnWithTypeAndName> > const&, std::__1::sha...
     clickhouse#DB::ExpressionActions::execute(DB::Block&, unsigned long&, bool) const
    clickhouse#DB::FilterTransform::transform(DB::Chunk&)
    clickhouse#DB::ISimpleTransform::transform(DB::Chunk&, DB::Chunk&)
   clickhouse#DB::ISimpleTransform::work()
                                                                                                                                                                                                                                                                                                                                                                                                                                                                              cl..
   clickhouse#void std::__1::__function::__policy_invoker<void ()>::__call_impl<std::__1::__function::__default_alloc_func<DB::PipelineExecutor::addJob(DB::ExecutingGraph::Node*)::$...
 clickhouse#DB::PipelineExecutor::executeStepImpl(unsigned long, unsigned long, std::__1::atomic<bool>*)
 clickhouse#DB::PipelineExecutor::executeImpl(unsigned long)
 clickhouse#DB::PipelineExecutor::execute(unsigned long)
 clickhouse#void std:: 1:: function:: policy invoker<void ()>:: call impl<std:: 1:: function:: default alloc func<ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPool::ThreadFromGlobalPoo
 clickhouse#ThreadPoolImpl<std:: 1::thread>::worker(std:: 1:: list iterator<std:: 1::thread, void*>)
 clickhouse#void* std:: 1:: thread proxy<std:: 1::tuple<std:: 1::unique ptr<std:: 1:: thread struct, std:: 1::default delete<std:: 1:: thread struct>>, void ThreadPoolImp..
 libpthread-2.27.so#start_thread
 clone.S (filtered by script)
```

Аппаратные метрики процессора

- man perf-stat(1) / perf_event_open(2)
- set metrics_perf_events_enabled = 1

logical_functions_medium, query no. 19: plot of PerfBranchInstructions_per_client_time to client_time





Что ещё может пойти не так?

"Все зелёные тесты похожи друг на друга, каждый красный тест красен по-своему."

— А. Эйнштейн

- Тест неправильно написан
 - Ошибка в описании теста
 - Ошибка в запросе
 - Слишком медленный
 - Слишком быстрый
- Ошибка среды
 - Кончилась память/место
 - ClickHouse упал/не запустился

- Изменилась производительность
 - Из-за наших изменений в коде (единственный true positive)
 - Статистический false positive
 - Поменялась сборка
 - граничные эффекты в компиляторе
 - разное расположение функций в бинарнике (BOLT, Propeller)
- Нестабильное время выполнения



Нестабильные запросы

- Неправильно написан запрос
 - о Слишком короткий, мерит шум
 - o system stop merges / optimize table
 final
 - o Таблица Buffer не того размера
- Неправильно написан код
- Внешние факторы



Нестабильные запросы (NUMA)

```
$ numactl --hardware
available: 2 \text{ nodes } (0-1)
node 0 cpus: 0 ... 41
node 0 size: 257844 MB
node 0 free: 99115 MB
node 1 cpus: 14 ... 55
node 1 size: 258043 MB
node 1 free: 88101 MB
node distances:
node 0 1
  0: 10 21
  1: 21 10
```

Intel(R) Xeon(R) CPU E5-2660 v4 @ 2.00GHz

```
$ numactl --cpunodebind=0
--membind=0
```


400 -> 100 нестабильных запросов.



Нестабильные запросы (iTLB)

• Копирование бинарника в huge pages (https://youtu.be/icfec1r_2q8?t=1587)

The "worst" code I've ever written. — A. Milovidov





Потребительские свойства

Чего хочется от тестов:

- Заканчиваться в обозримое время
 - 3ч для ПР
- Минимум false positives
 - игнор <5%
 - статистическая значимость
 - ожидаем до трёх false positive => можно их игнорировать
 - нестабильные тесты размечены вручную
- Результат можно интерпретировать
 - Инструменты интроспекции
 - Подробная инструкция
- Избежать вырождения в систему демонстрации зелёной галки

Как...

Пользователь автотестов производительности

Я хочу...

Видеть зелёную галку

Чтобы...

Спокойно помержить свой пулреквест

— тесты производительности по версии @ShitUserStory



С чем ещё можно сравнивать

- Среднее геометрическое изменений по всем тестам
 - Больше 1% что-то действительно поменялось
- Старые релизы
 - 20.8 -> 21.6 в среднем 10% ускорения
- Исторические данные

```
requeries rommits months months 1.09 billion | 7.24 thousand | 15.4 |

representation of the second second
```



```
WITH 0.05 AS s
SELECT old sha, new sha, event time, message, old value AS `old server`, new value AS `new server`,
before AS `prev 11 runs`, after AS `next 11 runs`, diff AS `diff, ratio`, stat threshold historical
AS `stat threshold, ratio, historical`, stat threshold AS `stat threshold, ratio, per-run`,
cpu model, query display name
FROM
(SELECT *, run attributes v1.value AS cpu model,
        median(old value) OVER (PARTITION BY run attributes v1.value, test, query index,
query display name ORDER BY event date ASC ROWS BETWEEN 11 PRECEDING AND CURRENT ROW) AS before,
        median (new value) OVER (PARTITION BY run attributes v1.value, test, query index,
query display name ORDER BY event date ASC ROWS BETWEEN CURRENT ROW AND 11 FOLLOWING) AS after,
        quantileExact(0.95)(abs(diff)) OVER (PARTITION BY run attributes v1.value, test, query index,
query display name ORDER BY event date ASC ROWS BETWEEN 37 PRECEDING AND CURRENT ROW) AS
stat threshold historical
    FROM query metrics v2
    LEFT JOIN run attributes v1 USING (old sha, new sha)
    WHERE (attribute = 'lscpu-model-name') AND (metric = 'client time') AND (pr number = 0)
     AND (test = 'logical functions medium') AND (query index = 19)
) AS t
ANY LEFT JOIN `gh-data`.commits ON new sha = sha
WHERE (((abs(after - before) / if(after > before, after, before)) AS step height) >= greatest(s,
stat threshold historical))
     AND (abs(diff) >= greatest(stat threshold, stat threshold historical, s))
     AND (abs(diff) \geq (0.7 * step height))
```

```
1dd57645c28f03e66347abffd13266a9c6ad2750
old sha:
                                   eeae539a9f02f00fa8f4d6ae2daf45ea8320818d
new sha:
                                   2021-04-30 21:50:24
event time:
                                   Merge pull request #23799 from
message:
kitaisreal/function-default-implementation-for-nulls-small-optimization
Function default implementation for nulls small optimization
                                   0.2608
old server:
                                   0.1985
new server:
                                  0.2603999972343445
prev 11 runs:
                                  0.19845000654459
next 11 runs:
diff, ratio:
                                  -0.239
stat threshold, ratio, historical: 0.074
stat threshold, ratio, per-run: 0.212
                                  Intel(R) Xeon(R) CPU E5-2660 v4 @ 2.00GHz
cpu model:
                    SELECT count() FROM
query display name:
test logical functions. 4 1 Nullable Mixed WHERE NOT ignore(xor(x1,x2,x3,x4))
```

Row 3:

Интересные факты

497 # This is a lateral join in bash... please forgive me.

— A. Kuzmenkov, "compare.sh"

- Вся обработка на clickhouse-local
 - ∘ а обвязка на bash
 - и на python (mymarilyn/clickhouse_driver)
 - ловили новые баги: в профайлере, в джоинах, в нативном протоколе и т.д.
- Почти самая тяжёлая проверка в нашем СІ
 - (после сборок)



Bcë.

Подпишитесь на наш блог https://clickhouse.tech/blog/en/



Александр Кузьменков github.com/akuzm t.me/akuzm akuzm@yandex-team.ru




Нестабильные запросы (jemalloc)

- soft page faults
- jemalloc two-phase purging

Что поменяли:

- 1) включили MADV_FREE
- 2) muzzy_decay_ms = 10s





Нестабильные запросы (jemalloc) (2)

