

## clickhouse在政务领域 实时数据检索及交换实践

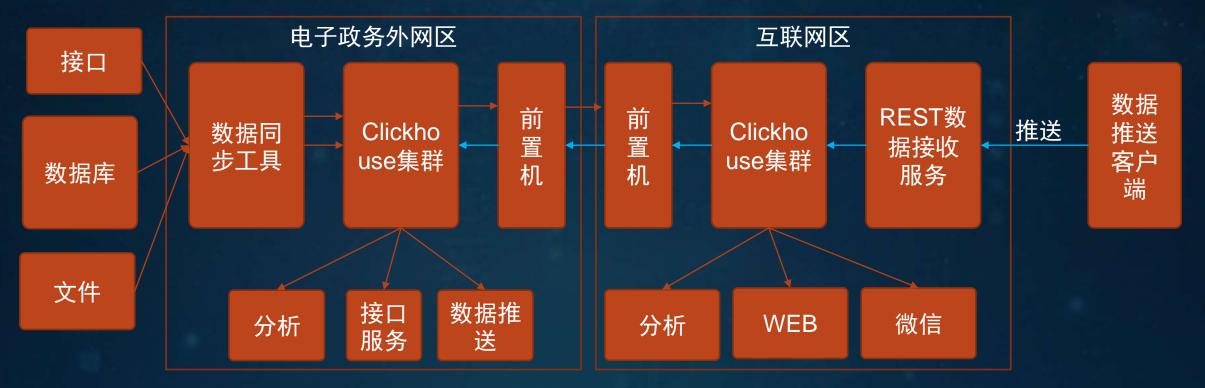
鲁四海

2021-12-11

#### 政务项目概况



汇聚地方上传数据、部委交换数据,经过清洗、合并、补全等数据治理后,向各部委、地方提供数据服务。



#### 特点:

- 1、数据入口多
- 2、数据质量差
- 3、含有超大文本计算

- 4、全量数据计算场景多
- 5、准确性要求高
- 6、基础设施架构限制性强

## clickhouse在实时数据交换共享场景中的应用



#### ◆跨网交换

最初:



#### 问题:

时间不同步,预留传输时间不准;

数据据量越来越大,互联网区数据拉取时间越来越长;

## clickhouse在实时数据交换共享场景中的应用



#### ◆跨网交换

#### 改进后:



#### 已解决的问题:

JSON格式被破坏;

内容过长,导致kafka写入失败;

UPDATE 合并问题;

## clickhouse在实时数据交换共享场景中的应用



◆跨部门跨地域数据交换



## clickhouse在精准全文检索场景中的应用



Elasticsearch方案

问题: 查准率 vs 查全率

原因:中文分词

ClickHouse方案:

无需分词;

无需预建索引;

解决查准率和查全率,且能有可验

证的明确的标准

Clickhouse集群 负载均衡 应用

#### 数据字典的使用



缘起:每次生成报表,都要join一个行政区划表

为什么不预处理生成一个行政区划名字段?

因为涉及行政区划的字段比较多,还可能出现重新计算的需求

```
w (dictionary)
   (name) sheng (/name)
  w (source)
   w(file)
        (path)/opt/dictionaries/kingThengQsBua_sheng.cov/path)
        (forust) CSVV(thNomes (forust)
     Ctile.
   (/source)
  w (lifetime)
     min/300 min?
     (nox 360 / mix
   (/lifetime)
  CtuoveD w.
     (flat
   (Inyout)
  w (atructure)
   WILLS.
       (numa ) code ( numa)
     (/1d)
    * (attribute)
       Chase name (mase)
       (type String / type)
       Smill value
     Cattribute?
    (/structure)
  (dictionary)
widletlonery?
   Change shill (name)
  * (source)
   wifile:
       (path)/opt/dictionaries/xingZhengQuBun_shi.csv(/path)
       (format) CSW:thNemer (format)
     Cilla)
   Cource:
  w Clifetine?
     min 300 min
     (pax 360 / nux
   (lifetime)
  w (larout)
     flat/
   Clayout)
  w (structure)
   wilds
```

Select ... from (...)as t1 left join t2 on ...



Select ... dictGet('dict name','col name', toUInt64OrZero()/xxHash64()) from t1

## 基于jdbc-bridge数据拉取和推送

◆初始方案: MySQL引擎





#### 问题:

- (1) MySQL Only
- (2) 字段类型匹配
- (3) 字段长度问题
- (4) 写入时间长,但无法准确了解运行进度

## 基于jdbc-bridge数据拉取和推送

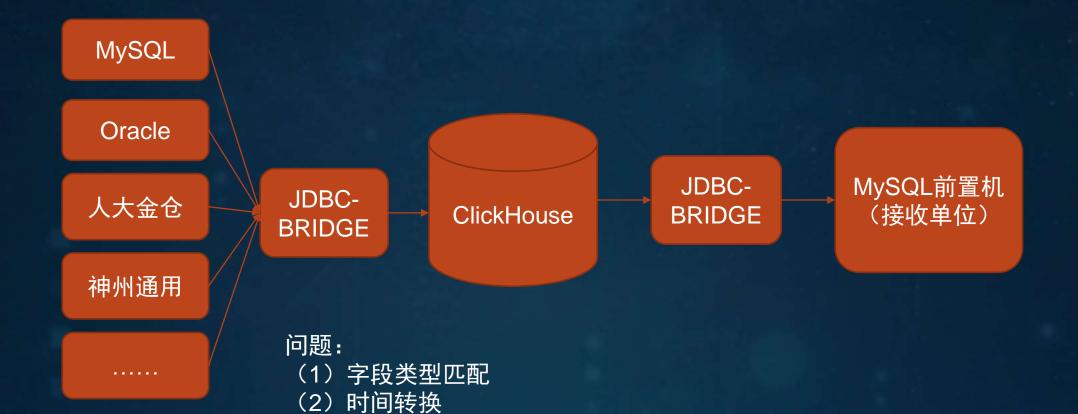
(3) 误写入

(4) JDBC内存溢出

(5) clickhouse 2 clickhouse异常

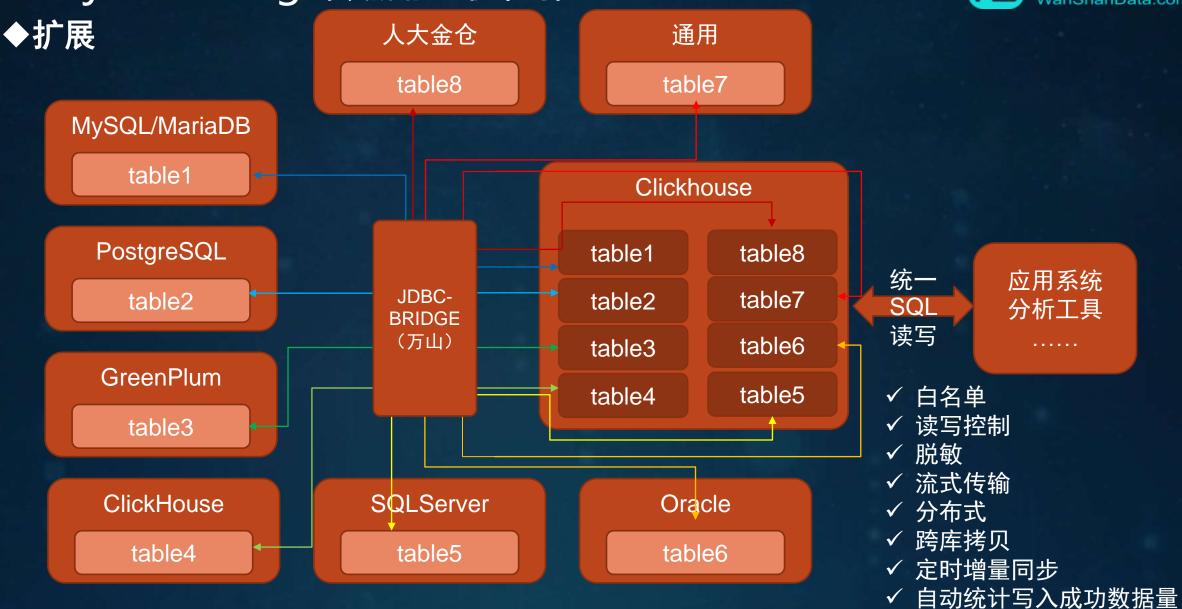
◆改进方案: JDBC-BRIDGE





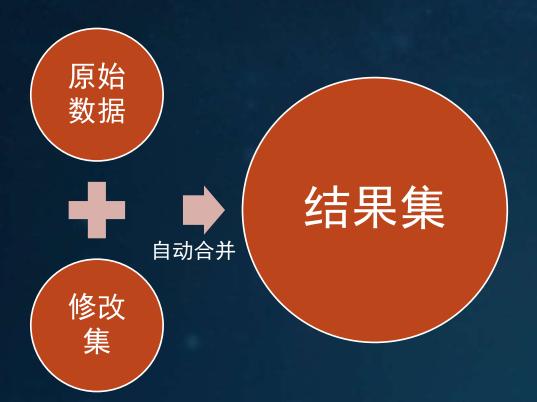
## 基于jdbc-bridge数据拉取和推送





#### 题外

◆数据操作溯源





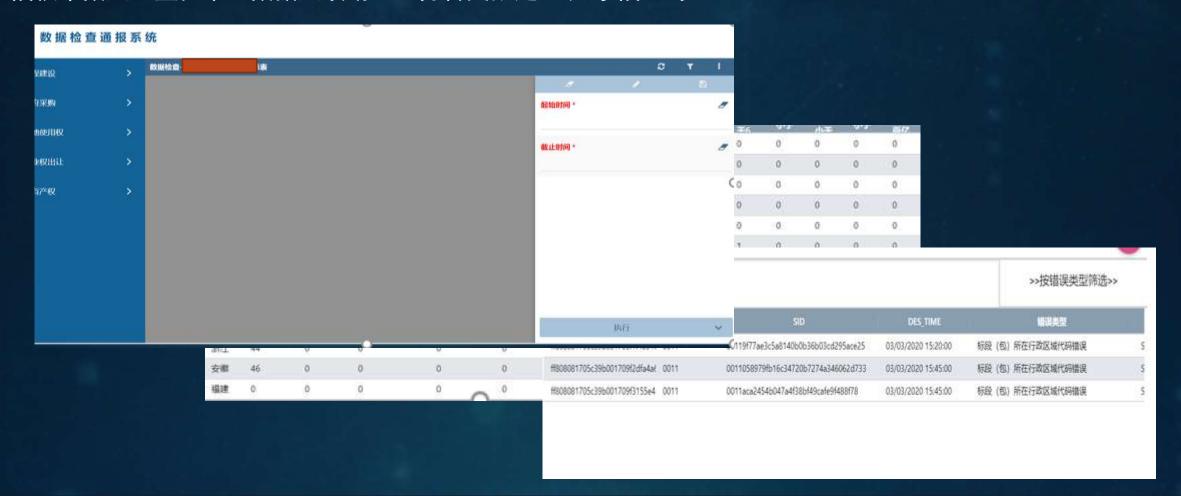
```
INSERT INTO watch (will, thi), col, wall) VALUES
 71.1e.io :) SELECT URL FROM view prod in DEA WIN WESULT ANNO DE MESSE SIL-'0034a447/e-0ela7e400daf4e21D951c9079a',
FROM view proc in DEA WIN FROUNT ANNO DN
WHERE hiD = "0034444730002a7e43004f4421099508079a"
  rmen in ret. Elapsed: 0.100 rmc. Processed 2.01 million rose, 45.46 MM (9.33 million rose/s., 410.93 MM/s.)
 71. is. in a) insert into upthicis, thl. onl. val) values ('0035a6477ebela1e400dat6a710992c507ea', 'proc in USA WIN RESULT AWWO De', 'UNL', 'WanShanbata, com') a
 INSERT INTO with (sin, th), will values
 71.18.10 1 DELECT URL FROM view proc in DEA WIN PRINCE ANNO ON WHERE STO-10036a6475e0e2a7e400daf4e210093c9079a'r
FROM VISW proc in DEA MIN MINISTER JUND DN MREHE HILL - 'DOJAGAT/SeDeZaTwalechataa218995=8079a'
  X root@Sean: /mnt/d/Temp
 oot#Sean:/mnt/d/Temp# java -jar increup.jar create_view
 生/mnt/d/Temp/increup_lib文件英中搜索JDBC驱动
支到 6 个JAR
 LF4J: Failed to load class "org.slf4j.impl.StaticLoggerBinder".
 LF4J: Defaulting to no-operation (NOP) logger implementation
 LF4]: See http://www.slf4].org/codes.html#StaticLoggerBinder for further details.
 上添加第1个JDBC驱动: ru. yandex. clickhouse. ClickHouseDriver
上添加第2个JDBC驱动: com. github. housepower. repackaged. comgithub. housepower. jdbc. ClickHouseDriver
上添加第3个JDBC驱动: com. kingbase. Driver
 日添加第4个IDBC驱动。 com.mysql.jdbc.Driver
日添加第5个IDBC驱动。 com.mysql.fabric.jdbc.FabricMySQLDriver
日添加第6个IDBC驱动。 oracle.jdbc.OracleDriver
  已添加第7个JDBC驱动; com informix, jdbc. IfxDriver
 生成可修改视图,请先输入Clickhouse地址、端口、用户名、密码,每行一个,如: localhost 8123 default password
然后输入以下命令开始创建: table 数据库名.表名 主键名 [—float64] [—drop]
```

### 题外



#### ◆数据质量评估评价

数据质量管理:即时数据检查系统,实时保证数据质量,实时知道数据的情况(记录数、字段枚举分布、字段枚举数量、空值率、数据量波动、业务含义限定、表/字段比对)

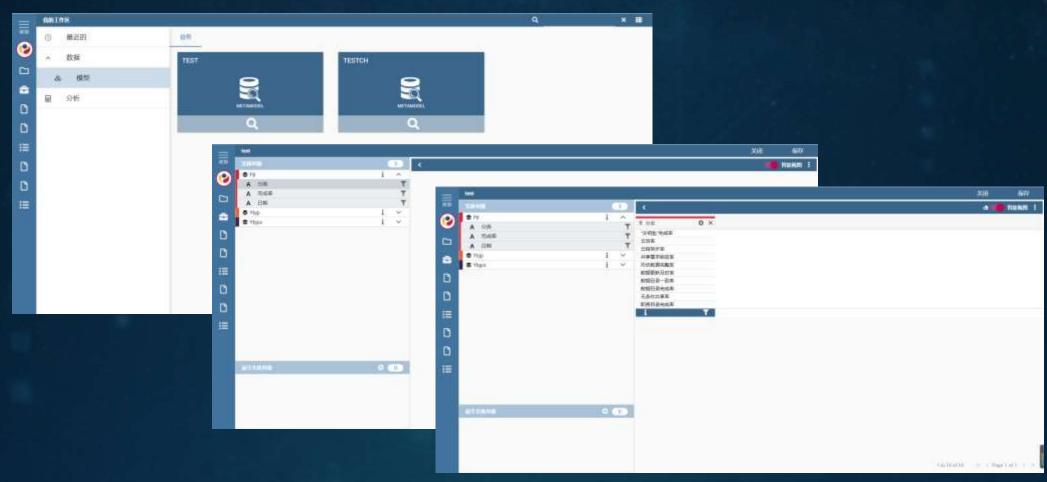






#### ◆自主查询

Clickhouse + knowage



## 关于开源的一点心得体会



- ◆开源不应只是代码,更重要的是想法
- ◆开源不是免费, 而是能承载创新的自由





# THANKS